

Kernel VAE: カーネル法を用いた次元削減

内海 佑麻 * ¹

¹ 慶應義塾大学理工学部情報工学科

2019/10/11

概 要

...

目 次

1	Introduction	1
2	ガウス過程と確率モデル	2
2.1	ガウス分布	2
2.2	ガウス過程 (GP)	2
2.3	ガウス過程回帰 (GPR)	2
2.4	ガウス過程潜在変数モデル (GP-LVM)	4
3	Deep Neural Network のカーネル法による近似	6
3.1	1 層の Feed Forward Neural Network	6
3.2	多層の Feed Forward Neural Network	8
4	Kernel Variational AutoEncoder	8
5	Experiments	9
6	Conclusion	9

1 Introduction

...

*uchiumi@ailab.ics.keio.ac.jp

2 ガウス過程と確率モデル

2.1 ガウス分布

分布の再生性 任意の $n \in \mathbb{N}$ と $\{a_i, b_i \in \mathbb{R}\}_{i=1}^n$ に対して、次が成り立つ.

$$X_i \sim i.i.d. \mathcal{N}(\mu_i, \sigma_i^2), \quad (i = 1, \dots, n) \quad (1)$$

$$\Rightarrow \sum_{i=1}^n a_i X_i + b_i \sim \mathcal{N} \left(\sum_{i=1}^n a_i \mu_i + b_i, \sum_{i=1}^n a_i^2 \sigma_i^2 \right) \quad (2)$$

条件つき分布の計算 任意の2つのベクトル $\mathbf{f}_n \in \mathbb{R}^n, \mathbf{f}_m \in \mathbb{R}^m$ に対して,

$$\begin{pmatrix} \mathbf{f}_n \\ \mathbf{f}_m \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \boldsymbol{\mu}_n \\ \boldsymbol{\mu}_m \end{pmatrix}, \begin{bmatrix} \Sigma_{nn} & \Sigma_{nm} \\ \Sigma_{nm}^T & \Sigma_{mm} \end{bmatrix} \right) \quad (3)$$

ならば、次が成り立つ.

$$\mathbf{f}_m | \mathbf{f}_n \sim \mathcal{N}(\boldsymbol{\mu}_{m|n}, \Sigma_{m|n}) \quad (4)$$

$$\text{where } \begin{cases} \boldsymbol{\mu}_{m|n} = \boldsymbol{\mu}_m + \Sigma_{nm}^T \Sigma_{nn}^{-1} (\mathbf{f}_n - \boldsymbol{\mu}_n) \\ \Sigma_{m|n} = \Sigma_{mm} - \Sigma_{nm}^T \Sigma_{nn}^{-1} \Sigma_{nm} \end{cases}$$

2.2 ガウス過程 (GP)

入力空間 \mathcal{X} 上の関数 $f: \mathcal{X} \rightarrow \mathbb{R}$ がガウス過程 (Gaussian Process, GP) に従うとは、 \mathcal{X} 上の任意の n 点 $\{x_i\}_{i=1}^n$ に対して、ベクトル $\mathbf{f} = (f(x_1), \dots, f(x_n))^T \in \mathbb{R}^n$ が n 次元ガウス分布に従うことをいう。ここで、確率変数 $\mathbf{f} \in \mathbb{R}^n$ が n 次元ガウス分布に従う時、その確率密度関数 $p(\mathbf{f})$ は、平均関数 $m(\cdot)$ と共分散関数 $v(\cdot, \cdot)$ を用いて

$$p(\mathbf{f}) = \frac{1}{(2\pi)^{n/2} |V(\mathbf{f})|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{f} - m(\mathbf{f}))^T V(\mathbf{f})^{-1} (\mathbf{f} - m(\mathbf{f})) \right) \quad (5)$$

と定められる。ただし、 $V(\mathbf{f})$ は共分散 $v(\mathbf{f}_i, \mathbf{f}_j)$ を ij 要素にもつ共分散行列である。ゆえに、関数 $f: \mathcal{X} \rightarrow \mathbb{R}$ がガウス過程 (Gaussian Process, GP) に従うとき、その挙動は平均関数 $m(\cdot)$ と共分散関数 $v(\cdot, \cdot)$ によって定められ、これを以下のように記述する。

$$f(\cdot) \sim \mathcal{GP}(m(\cdot), v(\cdot, \cdot)) \quad (6)$$

2.3 ガウス過程回帰 (GPR)

確率変数 $X \in \mathbb{R}^d, Y \in \mathbb{R}$ の実現値からなる n 個のデータサンプル $\mathcal{D} = \{\mathbf{x}_i, y_i\}_{i=1}^n$ を用いて、 X の値から Y の値を推定するモデル $f: X \rightarrow Y$ を特定することを回帰問題という。

すべての (\mathbf{x}, y) に対して、モデルの出力値 $f(\mathbf{x})$ と y との誤差を ε とおき、これが正規分布 $\mathcal{N}(0, \sigma^2)$ に従うと仮定すると回帰モデルは、

$$y = f(\mathbf{x}) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2) \quad (7)$$

あるいは、正規分布の再生性より、

$$y|\mathbf{x} \sim \mathcal{N}(f(\mathbf{x}), \sigma^2) \quad (8)$$

となる。また一般の回帰問題において、データサンプル $\mathcal{D} = \{X_i, Y_i\}_{i=1}^n$ とモデル $f: X \rightarrow Y$ に対して下式が成り立つことから、これはモデル f の分布に関するベイズ推論へ拡張できる。

$$p(f|\mathcal{D}) = \frac{p(\mathcal{D}|f)p(f)}{p(\mathcal{D})}, \quad i.e. \quad p(f|Y, X) = \frac{p(Y|X, f)p(f)}{p(Y|X)} \quad (9)$$

上のモデルにおいて、関数 f がガウス過程に従う場合、これをガウス過程回帰という。たとえば、関数 f に対して、

$$f(\cdot) \sim \mathcal{GP}(m(\cdot), k(\cdot, \cdot)) \quad (10)$$

を仮定すると、 $\mathbf{f}_n = (f(\mathbf{x}_1), \dots, f(\mathbf{x}_n))^T$ と $\mathbf{y}_n = (y_1, \dots, y_n)^T$ に対して、

$$\mathbf{f}_n \sim \mathcal{N}(m(X_n), K(X_n, X_n)) \quad (11)$$

$$\mathbf{y}_n \sim \mathcal{N}(m(X_n), K(X_n, X_n) + \sigma^2 I_n) \quad (12)$$

が成り立つ。ただし、 $m(X_n) = (m(\mathbf{x}_1), \dots, m(\mathbf{x}_n))^T$ 、 $K(X_n, K(X_n))_{ij} = k(f(\mathbf{x}_i), f(\mathbf{x}_j))$ 、 I_n は $n \times n$ の単位行列とする。式 (10) は、式 (9) でモデル f の事前分布 $p(f)$ を定めることに対応する。さらに、式 (8) と正規分布の共役性より、ガウス過程回帰では、事前分布 $p(f)$ と事後分布 $p(f|Y, X)$ が共に正規分布に従うため、データサンプル $\mathcal{D} = \{X_i, Y_i\}_{i=1}^n$ に基づく平均関数 $m(\cdot)$ と共分散関数 $k(\cdot, \cdot)$ の行列計算 ($O(n^2)$) のみで事後分布の形状が求められる。

さらに、未知の m 個のデータ $\{\mathbf{x}_i\}_{i=n+1}^{n+m}$ に対して、対応する $\{y_i\}_{i=n+1}^{n+m}$ の同時分布 (予測分布) を求めることもできる。式 (10) より、

$$\begin{pmatrix} \mathbf{f}_n \\ \mathbf{f}_m \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} m(X_n) \\ m(X_m) \end{pmatrix}, \begin{bmatrix} K(X_n, X_n) & K(X_n, X_m) \\ K(X_n, X_m)^T & K(X_m, X_m) \end{bmatrix} \right) \quad (13)$$

が成り立つから、式 (4) より、 \mathbf{f}_m の \mathbf{f}_n に対する予測分布は、

$$\mathbf{f}_m|\mathbf{f}_n \sim \mathcal{N}(E[\mathbf{f}_m|\mathbf{f}_n], V[\mathbf{f}_m|\mathbf{f}_n]) \quad (14)$$

$$where \begin{cases} E[\mathbf{f}_m|\mathbf{f}_n] = m(X_m) + K(X_n, X_m)^T K(X_n, X_n)^{-1} (\mathbf{f}_n - m(X_n)) \\ V[\mathbf{f}_m|\mathbf{f}_n] = K(X_m, X_m) - K(X_n, X_m)^T K(X_n, X_n)^{-1} K(X_n, X_m) \end{cases}$$

となり, \mathbf{f}_m の \mathbf{y}_n に対する予測分布は,

$$\mathbf{f}_m|\mathbf{y}_n \sim \mathcal{N}(E[\mathbf{f}_m|\mathbf{y}_n], V[\mathbf{f}_m|\mathbf{y}_n]) \quad (15)$$

$$\text{where } \begin{cases} E[\mathbf{f}_m|\mathbf{y}_n] = m(X_m) + K(X_n, X_m)^T (K(X_n, X_n) + \sigma^2 I_n)^{-1} (\mathbf{y}_n - m(X_n)) \\ V[\mathbf{f}_m|\mathbf{y}_n] = K(X_m, X_m) - K(X_n, X_m)^T (K(X_n, X_n) + \sigma^2 I_n)^{-1} K(X_n, X_m) \end{cases}$$

となる. よって, \mathbf{y}_m の \mathbf{y}_n に対する予測分布は,

$$\mathbf{y}_m|\mathbf{y}_n \sim \mathcal{N}(E[\mathbf{y}_m|\mathbf{y}_n], V[\mathbf{y}_m|\mathbf{y}_n]) \quad (16)$$

$$\text{where } \begin{cases} E[\mathbf{y}_m|\mathbf{y}_n] = m(X_m) + K(X_n, X_m)^T (K(X_n, X_n) + \sigma^2 I_n)^{-1} (\mathbf{y}_n - m(X_n)) \\ V[\mathbf{y}_m|\mathbf{y}_n] = K(X_m, X_m) - K(X_n, X_m)^T (K(X_n, X_n) + \sigma^2 I_n)^{-1} K(X_n, X_m) + \sigma^2 I_m \end{cases}$$

となる.

2.4 ガウス過程潜在変数モデル (GP-LVM)

確率変数 $X \in \mathbb{R}^Q, Y \in \mathbb{R}^D$ に対して, Y の N 個のデータサンプル $\{\mathbf{y}_i\}_{i=1}^N$ から, 生成モデル $p(Y|X)$ を特定することを考える. このとき, Y を観測変数, X を潜在変数と呼ぶ. 観測変数の観測値 (計画行列) を $\mathbf{Y}^n = \mathbb{R}^{n \times D}$, それを表現する潜在変数の観測値 (計画行列) を $\mathbf{X}^n \in \mathbb{R}^{n \times Q}$ とおく. すべての $i \in \{1, \dots, N\}$ と $d \in \{1, \dots, D\}$ に対して, 関数 $f: \mathbb{R}^Q \rightarrow \mathbb{R}$ を用いて, 生成過程:

$$\mathbf{y}_{id} = f(\mathbf{x}_i) + \varepsilon_i, \quad \varepsilon_i \sim i.i.d. \mathcal{N}(0, \sigma_\varepsilon^2) \quad (17)$$

を仮定し, さらに関数 f に対してガウス過程

$$f(\cdot) \sim \mathcal{GP}(0, k(\cdot, \cdot)) \quad (18)$$

を仮定すると,

$$p(\mathbf{y}_i|\mathbf{X}^n) = \prod_{d=1}^D p(\mathbf{y}_{id}) = \prod_{d=1}^D \mathcal{N}(\mathbf{y}_{id}|f(\mathbf{x}_i), \sigma_\varepsilon^2) \quad (19)$$

$$p(\mathbf{y}_d|\mathbf{X}^n) = \prod_{i=1}^n p(\mathbf{y}_{id}) = \mathcal{N}(\mathbf{y}_d|\mathbf{0}, \Sigma_{nn}) \quad (20)$$

となるから, 生成モデルの尤度は, 次式で与えられる.

$$p(\mathbf{Y}^n|\mathbf{X}^n) = \prod_{d=1}^D p(\mathbf{y}_d|\mathbf{X}^n) = \prod_{d=1}^D \mathcal{N}(\mathbf{y}_d|\mathbf{0}, \Sigma_{nn}) \quad (21)$$

$$= \prod_{d=1}^D \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma_{nn}|^{\frac{1}{2}}} \exp\left(-\frac{1}{2} \mathbf{y}_d^T \Sigma_{nn}^{-1} \mathbf{y}_d\right) \quad (22)$$

$$= \frac{1}{(2\pi)^{\frac{Dn}{2}} |\Sigma_{nn}|^{\frac{D}{2}}} \exp\left(-\frac{1}{2} \text{tr}(\Sigma_{nn}^{-1} \mathbf{Y}^n \mathbf{Y}^{nT})\right) \quad (23)$$

ただし,

$$\mathbf{\Sigma}_{nn} = \mathbf{K}_{nn} + \sigma_\varepsilon^2 \mathbf{I}_n \quad (24)$$

$$\mathbf{K}_{nn}(i, j) = k(\mathbf{x}_i, \mathbf{x}_j), \quad \forall(i, j) \quad (25)$$

とする.

最尤推定 \mathbf{Y}^n が与えられたときの \mathbf{X}^n の対数尤度は,

$$\log p(\mathbf{Y}^n | \mathbf{X}^n) = -\frac{Dn}{2} \log(2\pi) - \frac{D}{2} \log |\mathbf{\Sigma}_{nn}| - \frac{1}{2} \text{tr}(\mathbf{\Sigma}_{nn}^{-1} \mathbf{Y}^n \mathbf{Y}^{nT}) \quad (26)$$

となるから, これを目的関数として最大化すれば, \mathbf{X}^n の最尤推定量は, 次のように求められる.

$$\hat{\mathbf{X}}_{ML}^n = \underset{\mathbf{X}^n}{\operatorname{argmax}} \log p(\mathbf{Y}^n | \mathbf{X}^n) \quad (27)$$

$$(28)$$

MAP 推定 X^n の事前分布として,

$$p(X^n) = \prod_{q=1}^Q p(\mathbf{x}_q) = \prod_{q=1}^Q \mathcal{N}(\mathbf{x}_q | \mathbf{0}, \sigma_x^2 \mathbf{I}_N) \quad (29)$$

$$= \prod_{q=1}^Q \frac{1}{(2\pi\sigma_x^2)^{\frac{N}{2}}} \exp\left(-\frac{\mathbf{x}_q^T \mathbf{x}_q}{2\sigma_x^2}\right) \quad (30)$$

$$= \frac{1}{(2\pi\sigma_x^2)^{\frac{QN}{2}}} \exp\left(-\frac{1}{2\sigma_x^2} \text{tr}(\mathbf{X}^n \mathbf{X}^{nT})\right) \quad (31)$$

$$(32)$$

を仮定すると, ベイズの定理より, X の事後分布は,

$$p(X|Y) = \frac{1}{Z} p(Y|X) p(X) \quad (33)$$

となる. ただし, Z は規格化定数とする, よって, \mathbf{X}^n の事後確率は,

$$p(\mathbf{X}^n | \mathbf{Y}^n) \propto \log p(\mathbf{Y}^n | \mathbf{X}^n) p(\mathbf{X}^n) \quad (34)$$

$$= -\frac{Dn}{2} \log(2\pi) - \frac{D}{2} \log |\mathbf{\Sigma}_{nn}| - \frac{1}{2} \text{tr}(\mathbf{\Sigma}_{nn}^{-1} \mathbf{Y}^n \mathbf{Y}^{nT}) \quad (35)$$

$$- \frac{QN}{2} \log(2\pi\sigma_x^2) - \frac{1}{2} \text{tr}(\mathbf{X}^n \mathbf{X}^{nT}) \quad (36)$$

となるから, これを目的関数として最大化すれば, \mathbf{X}^n の MAP 推定量は, 次のように求められる.

$$\hat{\mathbf{X}}_{MAP}^n = \underset{\mathbf{X}^n}{\operatorname{argmax}} \log p(\mathbf{Y}^n | \mathbf{X}^n) p(\mathbf{X}^n) \quad (37)$$

3 Deep Neural Network のカーネル法による近似

3.1 1層の Feed Forward Neural Network

ニューラルネットワークの全結合層や畳み込み層における推論計算は、線形写像と非線形の活性化関数の組み合わせによって構成される。ここで、ある層の入力ベクトルを $\mathbf{x} \in \mathbb{R}^N$ ，出力ベクトルを $\mathbf{y} \in \mathbb{R}^M$ ，線形写像に対応する変換行列を $\mathbf{W} \in \mathbb{R}^{M \times N}$ ，活性化関数を $\phi: \mathbb{R}^M \rightarrow \mathbb{R}^M$ とすると、非線形関数 $f: \mathbf{x} \mapsto \mathbf{y}$ は以下のように構成される。

$$\mathbf{y} = f(\mathbf{x}) = \phi(\mathbf{W}\mathbf{x}) \quad (38)$$

なお、全結合層に置けるバイアスベクトルの追加に関しては、 \mathbf{x} と \mathbf{W} に次元を 1 つ追加することで上式と等価となり、畳み込み層に置けるフィルタ演算も `im2col` によって上式と等価となることに注意する。ここで、関数 f に対する内積 $f(\cdot)^T f(\cdot): \mathbf{x} \times \mathbf{x}' \mapsto \mathbb{R}$ を考える。活性化関数 ϕ として ReLU を仮定して、対応する指示関数

$$I(x) = \begin{cases} 1 & (x \geq 0) \\ 0 & (x < 0) \end{cases} \quad (39)$$

を定義すると、 $\forall \mathbf{x}, \mathbf{x}'$ に対する内積は、

$$f(\mathbf{x})^T f(\mathbf{x}') = \sum_{i=1}^M I(\mathbf{w}_i^T \mathbf{x}) I(\mathbf{w}_i^T \mathbf{x}') (\mathbf{w}_i^T \mathbf{x}) (\mathbf{w}_i^T \mathbf{x}') \quad (40)$$

となる。ただし、 $\mathbf{w}_i = (\mathbf{W}_{i1}, \dots, \mathbf{W}_{iN})^T \in \mathbb{R}^N$ とする。いま、行列 \mathbf{W} の各要素 \mathbf{W}_{ij} を i.i.d. となる確率変数と仮定すると、すべての i に対して \mathbf{w}_i も i.i.d. となる、また、確率変数 \mathbf{W}_{ij} は平均と分散として、それぞれ 0, σ_w^2 を与える。

$$\forall i, j, \mathbf{W}_{ij} \sim i.i.d. \quad (41)$$

$$E[\mathbf{W}_{ij}] = 0, V[\mathbf{W}_{ij}] = \sigma_w^2 \quad (42)$$

すると、中心極限定理 (Central Limit Theorem) より、 \mathbf{x} を固定したとき、任意の \mathbf{w} の関数 $C(\mathbf{w})$ に対して、

$$E \left[\frac{1}{M} \sum_{i=1}^M C(\mathbf{w}_i) \right] \rightarrow \int d\mathbf{w} \frac{\exp(-\frac{\|\mathbf{w}\|^2}{2})}{(2\pi\sigma_w^2)^{N/2}} C(\mathbf{w}) \quad (M \rightarrow \infty) \quad (43)$$

が満たされるから、

$$\begin{aligned} E \left[\frac{1}{M} f(\mathbf{x})^T f(\mathbf{x}') \right] &= E \left[\frac{1}{M} \sum_{i=1}^M I(\mathbf{w}_i^T \mathbf{x}) I(\mathbf{w}_i^T \mathbf{x}') (\mathbf{w}_i^T \mathbf{x}) (\mathbf{w}_i^T \mathbf{x}') \right] \rightarrow \\ &\int d\mathbf{w} \frac{\exp(-\frac{\|\mathbf{w}\|^2}{2})}{(2\pi\sigma_w^2)^{N/2}} I(\mathbf{w}^T \mathbf{x}) I(\mathbf{w}^T \mathbf{x}') (\mathbf{w}^T \mathbf{x}) (\mathbf{w}^T \mathbf{x}') \quad (M \rightarrow \infty) \end{aligned} \quad (44)$$

が成り立つ。式 (44) 右辺を整理すると、以下の定理が導かれる。

定義 1 (*arc-cosine kernel*) 任意の 2 つのベクトル $\mathbf{x}, \mathbf{x}' \in \mathcal{X} \subset \mathbb{R}^N$ に対して,

$$\theta = \cos^{-1} \left(\frac{\mathbf{x}^T \mathbf{x}'}{\|\mathbf{x}\| \|\mathbf{x}'\|} \right) \quad (45)$$

$$J(\theta) = \sin \theta + (\pi - \theta) \cos \theta \quad (46)$$

とおき, *arc-cosine* カーネル

$$k^{(1)}(\mathbf{x}, \mathbf{x}') = \frac{1}{\pi} \|\mathbf{x}\| \|\mathbf{x}'\| J(\theta) \quad (M \rightarrow \infty) \quad (47)$$

を定義する.

定理 1 各要素 W_{ij} が互いに独立に正規分布 $\mathcal{N}(0, 1)$ に従うランダム行列 $\mathbf{W} \in \mathbb{R}^{M \times N}$ を考える. 活性化関数として *ReLU* 関数 ϕ を用いて, 1 層のニューラルネットワークに相当する関数 $f: \mathbb{R}^N \rightarrow \mathbb{R}^M$:

$$f(\mathbf{x}) = \phi(\mathbf{W}\mathbf{x}) \quad (\forall \mathbf{x} \in \mathbb{R}^N) \quad (48)$$

を考える. このとき任意の $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^N$ に対して,

$$E \left[\frac{1}{M} f(\mathbf{x})^T f(\mathbf{x}') \right] \rightarrow \frac{1}{\sigma_w^N} k^{(1)}(\mathbf{x}, \mathbf{x}') \quad (M \rightarrow \infty) \quad (49)$$

が成り立つ.

定理 2 $\mathcal{X} \times \mathcal{X}$ 上の関数

$$k^{(1)}(\mathbf{x}, \mathbf{x}') = \frac{1}{\pi} \|\mathbf{x}\| \|\mathbf{x}'\| J(\theta) \quad (50)$$

は半正定値関数である.

定理 3 (*カーネル関数存在定理*) 任意の対称行列 $K \in \mathbb{R}^{n \times n}$ が半正定値ならば, データ空間 \mathcal{X} 上の n 点 $\{\mathbf{x}_i\}_{i=1}^n$ と, 特徴空間 $\mathcal{F} \subset \mathbb{R}^n$ 上の n 次元特徴ベクトル $\{f(\mathbf{x}_i)\}_{i=1}^n$ がそれぞれ存在して,

$$K_{ij} = \langle f(\mathbf{x}_i), f(\mathbf{x}_j) \rangle_{\mathcal{F}} = \sum_{k=1}^n f(\mathbf{x}_i)_k f(\mathbf{x}_j)_k \quad (51)$$

が成り立つ. さらに, $k(\mathbf{x}_i, \mathbf{x}_j) = K_{ij}$ とおけば, 半正定値関数 $k: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ が定義される.

定理 3 から, カーネル関数 $k: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ を定義せずとも, 与えられたデータサンプルから構成された半正定値対称行列を作ること, それが何らかのカーネル関数によるグラム行列に相当することが保証される. よって, 定理 1 と定理 2 より, 式 (50) を共分散関数にもつガウス過程が 1 層の NeuralNetwork の近似となることがわかる.

3.2 多層の Feed Forward Neural Network

1 層の Feed Forward Neural Network に関する議論は、正定値カーネルの線形性より、容易に多層へと拡張することができる。一般性を失うことなく、 $L > 0$ 層からなる Feed Forward Neural Network を考え、各層の線形写像に対応する重み行列 $\mathbf{W}^{(l)}$ に対して、固定された σ_w^2 を与えて、

$$\forall l \in [1, L] \subset \mathbb{N}, \quad \mathbf{W}_{ij}^{(l)} \sim i.i.d. \mathcal{N}(0, \sigma_w^2) \quad (52)$$

を仮定する。第 l 層のユニット数を $N^{(l)}$ 、第 l 層の空間を $\mathcal{T}^{(l)}$ 、第 l 層の出力を得る関数を $f^{(l)} : \mathcal{X} \rightarrow \mathcal{T}^{(l)}$ とおく。任意の入力データ $\mathbf{x}, \mathbf{x}' \in \mathcal{X}$ に対して、Neural Network の第 l 層に対応する共分散関数 $k^{(l)} : \mathcal{T}^{(l)} \times \mathcal{T}^{(l)} \rightarrow \mathbb{R}$ は、次の漸化式で求められる。

$$\begin{aligned} k^{(1)}(\mathbf{x}, \mathbf{x}') &= Cov \left[f^{(1)}(\mathbf{x}), f^{(1)}(\mathbf{x}') \right] \\ &= Cov \left[\phi(\mathbf{W}^{(1)}\mathbf{x}), \phi(\mathbf{W}^{(1)}\mathbf{x}') \right] \\ &= \frac{1}{\pi \sigma_w^{N^{(1)}}} \|\mathbf{x}\| \|\mathbf{x}'\| J(\theta^{(0)}) \end{aligned} \quad (53)$$

$$\begin{aligned} k^{(l+1)}(\mathbf{x}, \mathbf{x}') &= Cov \left[f^{(l+1)}(\mathbf{x}), f^{(l+1)}(\mathbf{x}') \right] \\ &= Cov \left[\phi(\mathbf{W}^{(l+1)} \dots \phi(\mathbf{W}^{(1)}\mathbf{x})), \phi(\mathbf{W}^{(l+1)} \dots \phi(\mathbf{W}^{(1)}\mathbf{x}')) \right] \\ &= \frac{1}{\pi \sigma_w^{N^{(l+1)}}} \sqrt{k^{(l)}(\mathbf{x}, \mathbf{x})} \sqrt{k^{(l)}(\mathbf{x}', \mathbf{x}')} J(\theta^{(l)}) \end{aligned} \quad (54)$$

ただし、

$$J(\theta^{(l)}) = \sin \theta^{(l)} + (\pi - \theta^{(l)}) \cos \theta^{(l)} \quad (55)$$

$$\theta^{(l)} = \begin{cases} \cos^{-1} \left(\frac{\mathbf{x}^T \mathbf{x}'}{\|\mathbf{x}\| \|\mathbf{x}'\|} \right) & (l = 0) \\ \cos^{-1} \left(\frac{k^{(l)}(\mathbf{x}, \mathbf{x}')}{\sqrt{k^{(l)}(\mathbf{x}, \mathbf{x})} \sqrt{k^{(l)}(\mathbf{x}', \mathbf{x}')}} \right) & (l \neq 0) \end{cases} \quad (56)$$

とする。以上の結果から、入力から第 l 層の各ユニットの出力値を得る関数 $f_i^{(l)} : \mathcal{X} \rightarrow \mathbb{R}$ は以下のガウス過程で近似できる。

$$f_i^{(l)}(\cdot) \sim \mathcal{GP}(0, k^{(l)}(\cdot, \cdot)), \quad (i = 1, \dots, N^{(l)}) \quad (57)$$

4 Kernel Variational AutoEncoder

前章での議論から、GP-LVM における潜在変数 X と観測関数 Y に対する確率モデル $p(Y|X)$ を、多層の Feed Forward Neural Network に相当する関数

$$f(\mathbf{x}) = \phi(\mathbf{w}^T \mathbf{x}) \quad (58)$$

によって表現することを考える。

5 Experiments

6 Conclusion